基于神经算子的 Burgers 方程传播前沿预测：公开数据上的泛化与物理修正

2026 年 11 月

摘要

本文基于 PDEBench 公开的 1D Burgers 数据，研究神经算子对传播激波/前沿的预测能力。以 FNO1D 为主模型、U-Net1D 为基线，先做一步监督训练，再尝试加入 Burgers 方程残差进行微调。实验表明，FNO1D 的一步相对 L_2 误差为 1.84×10^{-3}，100 步自回归 rollout 平均误差为 0.077，明显优于 U-Net1D 的 5.79×10^{-3} 和 0.433。一步 PDE 微调把 rollout 平均误差进一步降到 0.061，但三个随机种子的误差棒有重叠，只能视为小幅改善。分布外实验中，模型对更尖锐的 $\nu=0.001$ 仍能保持较小的前沿速度误差，但对更平滑的 $\nu=0.1$ 基本失效，呈现出明显的不对称性。sequence-level PDE loss 和多 ν 参数条件化均未取得正收益，本文将其作为负结果进行分析。

关键词：Burgers 方程；神经算子；Fourier Neural Operator；物理信息机器学习；分布外泛化

1 引言

Burgers 方程

$$u_t + u\,u_x = \nu\,u_{xx} \tag{1}$$

是流体、交通流和非线性波中的经典 PDE。粘性项会使初始波形形成传播的激波/前沿，因此它既能体现 PDE 结构，又适合作为神经算子代理模型的测试问题。本文使用 PDEBench 公开数据，主要目标围绕这三个问题展开：

1. FNO1D 能否准确预测 Burgers 的时空演化？
2. 加入 PDE 残差能否改善长时间 rollout？
3. 从单一 ν 训练出的模型，能否泛化到更尖锐或更平滑的 ν？

本文的主要工作包括：

1. 在 PDEBench 1D Burgers 上建立 FNO1D / U-Net1D 基线；
2. 比较一步 PDE 残差微调与 data-only 微调；
3. 构造 $\nu=0.001$ 和 $\nu=0.1$ 的 OOD 测试；
4. 引入前沿位置/速度指标，分析全局 L_2 之外的行为；
5. 报告 sequence-level PDE 和多 ν 条件化的负结果。

2 数据

数据来自 PDEBench 的 `1D_Burgers_Sols_Nu0.01.hdf5`（DOI: 10.18419/darus-2986）。单个文件约 7.7 GB，直接下载全部数据速度慢，且没有必要。本文的具体处理过程是：先读取 HDF5 中的 `tensor`、`t-coordinate` 和 `x-coordinate`，确认数据形状；再用 HTTP Range 只请求前 200 条轨迹，保存为本地 `.npz` 文件。PDEBench 的 Burgers 文件里 `t-coordinate` 有 202 个时间边界，而 `tensor` 只有 201 个时间快照，因此读取后将时间坐标截断到 201 个，避免维度不一致。

数据结构：

$$u \in \mathbb{R}^{200\times 201\times 1024} \tag{2}$$

三个维度分别为样本、时间和空间；$x \in [0,1]$，$t \in [0,2.01]$。按轨迹划分为 160 条训练、20 条验证、20 条测试，避免同一轨迹的时空点同时出现在训练集和测试集。归一化统计量只从训练集计算，验证集、测试集和 OOD 数据都沿用这组均值和标准差，防止信息泄漏。

OOD 数据：

1. $\nu = 0.001$：100 条轨迹，前沿更尖锐；
2. $\nu = 0.1$：100 条轨迹，前沿更平滑。

OOD 评估取前 20 条轨迹，rollout 100 步。这里有意改变 ν，从而让一个方向让激波更尖锐，另一个方向让激波更平滑，从而可以用来观察模型在不同前沿尺度上的失效模式。

> 严格说，Burgers 数据中的结构是粘性激波/传播前沿，不是单一速度的永久行波。本文使用“前沿”一词。

3 方法

3.1 FNO1D

FNO1D 由 lifting 层、若干 Fourier block 和 projection 层组成。每个 Fourier block 包含：

1. 保留低阶模态的谱卷积；
2. 逐点卷积；
3. GELU 激活。

谱卷积只保留前 16 个 Fourier 模态，把其余高频分量置零；每个 block 将谱卷积与逐点卷积分支相加，再经过 GELU。输入为归一化剖面 $u(t) \in \mathbb{R}^{1024}$，输出为 $u(t+1)$。选择 FNO 的原因是它通过频域卷积获得全局感受野，更适合描述前沿在空间上的整体传播；U-Net 的感受野主要受卷积核和下采样层数限制，对长时间、长距离传播的建模能力较弱。

3.2 U-Net1D

U-Net1D 作为卷积基线，包含两层下采样、两层上采样和跳连。它与 FNO 使用相同的数据划分、标准化和训练预算。

3.3 一步 PDE 微调

在监督训练之后，加入 Burgers 残差：

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \lambda \mathcal{L}_{\text{PDE}} \tag{3}$$

$$R = \frac{u_{t+1} - u_t}{\Delta t} + u_t \frac{\partial u_t}{\partial x} - \nu \frac{\partial^2 u_t}{\partial x^2} \tag{4}$$

其中时间导数用前向差分，空间一阶、二阶导数用中心差分；所有导数都在物理尺度的 u 上计算，而不是在标准化后的 u 上计算。为了让 PDE loss 和数据 loss 量级可比，使用无量纲化：

$$R_{\text{norm}} = R \cdot \frac{\Delta t}{u_{\text{std}}} \tag{5}$$

训练时取 $\lambda = 10^{-3}$，从 40 epoch 的 checkpoint 出发，再微调 10 个 epoch，学习率降到 10^{-4}。从而在已有的一步预测器上增加局部物理约束。

3.4 评价指标

1. 一步相对 L_2；
2. 自回归 rollout 的相对 L_2（10/50/100 步）；
3. 前沿位置误差；
4. 前沿速度误差。

前沿位置用最大空间梯度定位：

$$x_f(t) = \arg\max_x \left| \frac{\partial u}{\partial x} \right| \tag{6}$$

在周期域上用 64 个网格点的窗口跟踪，速度由 $x_f(t)$ 的线性拟合得到。由于数据中可能有多条激波，跟踪器偶尔会锁到另一条激波上，导致原始位置误差出现约 0.5 的跳变，因此同时报告“去常数偏移后的位置误差”（aligned position MAE）。raw 指标反映“有没有跟住同一条激波”，aligned 指标反映“轨迹有没有整体漂移”，两者结合看比单独看全局 L_2 更接近 PDE 关心的传播行为。

4 实验设置

1. FNO1D：width 32，modes 16，4 个 Fourier block，72,001 参数；
2. U-Net1D：base width 16，46,001 参数；
3. 损失：归一化 MSE；
4. 优化器：AdamW，学习率 10^{-3}；
5. batch size 32；
6. 40 个 epoch，早停；
7. FNO 跑 3 个随机种子，U-Net 跑 1 个种子；
8. PDE 微调：从对应 seed 的 checkpoint 出发，再训练 10 个 epoch，学习率 10^{-4}。

训练采用 one-step teacher forcing：每次从轨迹中取相邻两帧 (u_t, u_{t+1})，输入 u_t，监督 u_{t+1}。验证集只用于选择 checkpoint 和早停，测试集不参与调参。FNO 的三个 seed 使用相同的数据划分和训练预算，报告均值与标准差；U-Net 只跑一个 seed，作为计算量受限下的对照。

5 结果与分析

5.1 基线

表 1 基线模型的一步与自回归精度（rel L_2，括号内为标准差）

模型	参数量	1 步	10 步	50 步	100 步	100 步均值
FNO1D (3 seeds)	72,001	**0.00184**	0.029	0.079	0.132	**0.077**
		(0.00003)	(0.008)	(0.009)	(0.037)	(0.008)
U-Net1D (1 seed)	46,001	0.00579	0.079	0.505	0.729	0.433

FNO 的一步误差约为 U-Net 的 1/3，100 步 rollout 平均误差约为 U-Net 的 1/5.6。FNO 能复现斜向传播的激波/前沿结构，但尖锐前沿被明显平滑。

这个差距不是单纯的参数量差异。FNO 的谱卷积在频域上做全局混合，能一次性看到整个周期域，因此更容易学到大尺度前沿的传播方向；U-Net 主要依赖局部卷积，感受野随层数增长有限，在自回归 rollout 中局部误差会逐步累积。另一方面，FNO 只保留前 16 个模态，相当于对高频做低通滤波，因此原始模型能抓住大尺度传播、却会把尖锐激波抹平。针对这个“全局结构正确、局部锐度不足”的现象，我们后续进行了 PDE 微调。

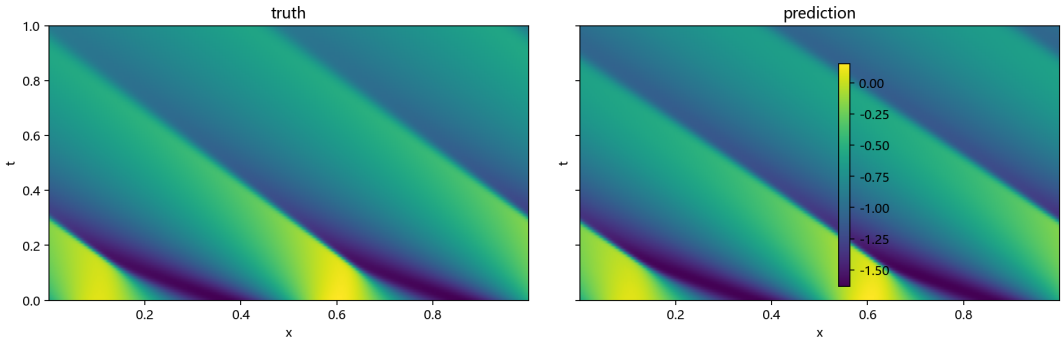


图 1 FNO1D 预测与真值的时空热图（rollout）

5.2 一步 PDE 微调

PDE 微调在 one-step 和 rollout 平均上都略有改善，但三个 seed 的误差棒明显重叠，因此只能视为“有希望”，不能视为统计显著。$\lambda = 10^{-2}$ 在 seed 0 上反而变差，说明权重需要调整。

从机制上看，这个结果是可以理解的。当前 PDE 残差只约束 $u_t \to u_{t+1}$ 的局部关系，并没有直接约束 10 步、50 步之后的误差累积；因此它能略微改善一步预测，却不能从根本上

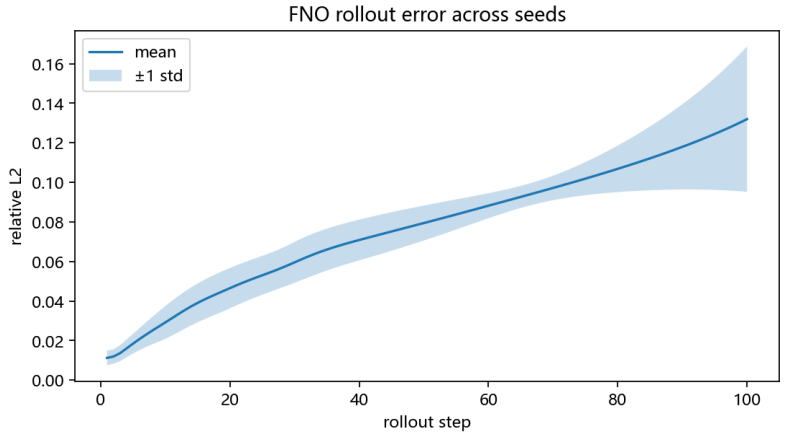


图 2　三个随机种子上的 rollout 误差均值与标准差

表 2　一步 PDE 微调与 data-only 微调的对比

模型	一步 rel L_2	100 步平均
FNO baseline（3 seeds）	0.00184 ± 0.00003	0.077 ± 0.008
FNO + data-only FT（3 seeds）	0.00171 ± 0.00021	0.065 ± 0.015
FNO + PDE FT（3 seeds）	$\mathbf{0.00153 \pm 0.00010}$	$\mathbf{0.061 \pm 0.015}$

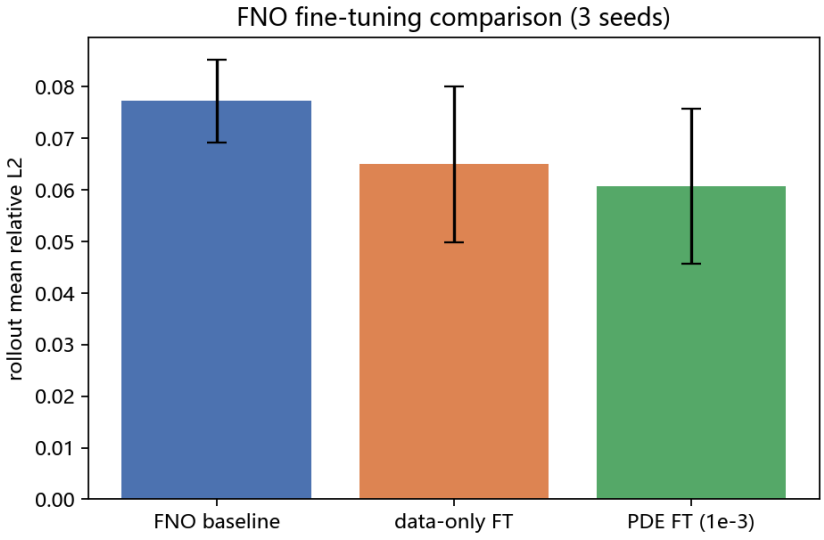


图 3　基线、data-only 微调与 PDE 微调的 rollout 误差对比

解决 rollout 漂移。另外，data-only 微调本身也会因为多训练了 10 个 epoch 而变好，所以 PDE 的净收益需要用 data-only 作为对照，不能把“比 40 epoch baseline 好”全部归因于物理损失。

5.3 OOD 与前沿指标

表 3　分布内与分布外（OOD）的前沿指标

模型	ν	rollout mean rel L_2	aligned position MAE	speed MAE
FNO baseline	0.01（ID）	0.0765	0.0081	0.0329
FNO baseline	0.001（OOD）	0.1591	0.0068	0.0267
FNO baseline	0.1（OOD）	0.7897	0.0533	0.1620
FNO + PDE	0.01（ID）	**0.0521**	**0.0052**	**0.0158**
FNO + PDE	0.001（OOD）	**0.1474**	**0.0048**	**0.0180**
FNO + PDE	0.1（OOD）	0.7901	0.0524	0.1537

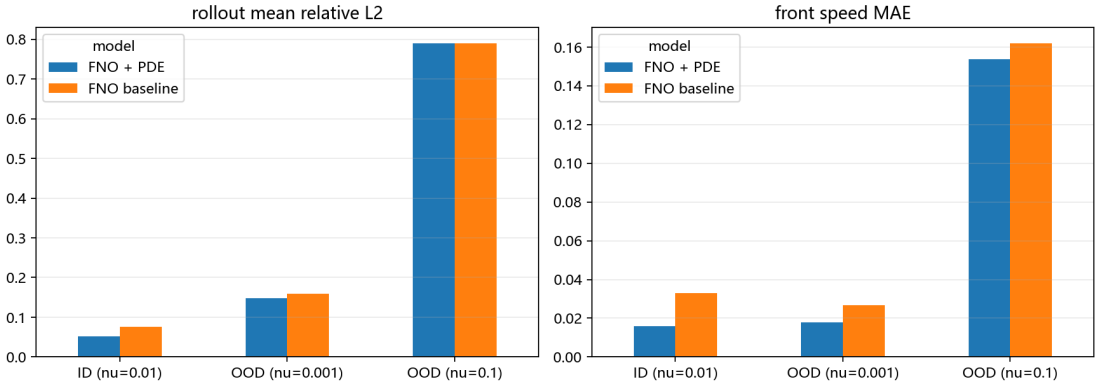


图 4　不同 ν 下的 rollout 误差与前沿速度误差

OOD 失败是不对称的：

1. 对更尖锐的 $\nu = 0.001$，全局 L_2 变差，但前沿位置和速度仍抓得住；
2. 对更平滑的 $\nu = 0.1$，误差接近 0.8，速度误差也很大，模型基本失效；
3. PDE 微调在 ID 和 $\nu = 0.001$ 上略有帮助，但对 $\nu = 0.1$ 没有改善。

这种不对称主要是因为“分布差异的大小”。$\nu = 0.001$ 的前沿更尖锐，局部梯度更大，但它仍然保留了与训练集相同的“斜向传播激波”结构；模型虽然画不出最锐的细节，但能抓住前沿的大致位置和速度。相比之下，$\nu = 0.1$ 的粘性明显更强，激波更宽、更平滑，前沿速度和波形结构都偏离训练分布；模型在训练中从未见过这种平滑 regime，误差就会迅速累积。这说明当前模型学到的更多是 $\nu = 0.01$ 附近的特定动力学，而不是对 Burgers 方程的一般解算子。

5.4 失败尝试

Sequence-level PDE loss：把 PDE 残差作用在 $H = 5$ 步自回归展开上。PDE 梯度会放大预测误差，训练不稳定；降低 λ 只能部分缓解。$H = 2$ 并 detach 第二步后仍无改善，rollout 平均约 0.10，明显差于一步 PDE 微调的 0.061。

多 ν 联合训练 + 常数 $\log\nu$ 通道：训练 $\nu = 0.001/0.01$，留出 $\nu = 0.1$。25 epoch 后联合测试 rollout 平均 0.391，留出 $\nu = 0.1$ 的 rel L_2 为 8.60，完全失败。说明仅把参数拼成输入通道不足以解决跨参数泛化。

5.2 和 5.3 作为负结果保留，用于说明“PDE 残差”和“参数条件”并不是无条件有效。sequence PDE 的核心问题是：自回归展开后的预测误差会进入下一步输入，PDE 残差又把这些带误差的预测纳入梯度，相当于用不稳定的长轨迹去约束模型；detach 只能切断梯度，不能消除输入分布偏移。多 ν 条件化的核心问题则是：常数通道对谱卷积的调制太弱，两个 ν 的动力学又差异较大，共享的谱卷积很难同时拟合，最终表现为欠拟合和 OOD 崩溃。

6 结论

1. 在 PDEBench 1D Burgers 上，FNO1D 的一步和 rollout 精度都明显优于 U-Net1D。
2. FNO 能捕捉大尺度前沿传播，但会平滑尖锐激波；误差随 rollout 累积。
3. 一步 PDE 微调带来小幅改善，但方差较大，不能宣称显著优于 data-only。
4. OOD 泛化是不对称的：更尖锐的 $\nu = 0.001$ 相对可接受，更平滑的 $\nu = 0.1$ 基本失效。
5. sequence-level PDE 和多 ν 常数通道条件化在当前实现下均为负结果。
6. 当前主结果应使用单 ν FNO + one-step PDE 微调；跨参数泛化仍未解决。

综上所述，本文最有价值的结论不是“PDE loss 一定有效”，而是在公开 Burgers 数据上，稳定的 one-step 监督训练比复杂的 sequence-level 约束更可靠；轻量 PDE 正则能改善局部精度，但不能替代长期 rollout 训练；真正的跨 ν 泛化需要更强的参数条件机制，而不是简单拼接一个常数通道。

7 局限与复现

1. 只使用 $\nu = 0.01$ 的 200 条轨迹作为主训练集，参数覆盖有限；
2. U-Net 只跑了 1 个 seed，对比不够充分；
3. PDE 微调只训练 10 个 epoch，权重未系统调优；
4. 前沿跟踪在有多条激波时可能锁到不同激波，因此同时报告 raw 和 aligned 位置误差。

参考文献

[1] Takamoto, M., Praditia, T., Leiteritz, R., MacKinlay, D., Alesiani, F., Pflüger, D., Niepert, M. *PDEBench: An Extensive Benchmark for Scientific Machine Learning.* NeurIPS 2022 Datasets and Benchmarks.

[2] Li, Z., Kovachki, N., Azizzadenesheli, K., et al. *Fourier Neural Operator for Parametric Partial Differential Equations*. ICLR 2021.

[3] Raissi, M., Perdikaris, P., Karniadakis, G. E. *Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics, 2019.

[4] Burgers, J. M. *A mathematical model illustrating the theory of turbulence*. Advances in Applied Mechanics, 1948.